


Control autónomo de un robot móvil usando ROS2, Aprendizaje por Refuerzo y SLAM

Máster Universitario en Ingeniería de Sistemas y de Control

Estudiante: Javier Arambarri Calvo

Directores: Raúl Fernández Fernández,
Jesús Chacón Sombria

Curso académico: 2025/2026



Trabajo de Fin de Máster - 21/09/2026

ÍNDICE



1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

ÍNDICE



1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

1. Introducción y motivación

CONTROL AUTÓNOMO



Sentido vestibular:

conocer posición y movimiento en el espacio



¡SLAM! – *Simultaneous Localization and Mapping* –

Técnica “**pasiva**”: procesa datos sensoriales para obtener mapa y posición.




**Sistema externo de navegación,
desacoplado de SLAM**

Robótica móvil



***Desconoce cómo afecta su movimiento a
la calidad del mapa y su localización***



1. Introducción y motivación

A-SLAM – Active Simultaneous Localization and Mapping –

Sentido vestibular:

conocer posición y movimiento en el espacio



¡SLAM! – *Simultaneous Localization and Mapping* –

Técnica “pasiva”: procesa datos sensoriales para obtener mapa y posición.



Agente de **Aprendizaje Por Refuerzo (RL)**


Integra la toma de decisiones bajo incertidumbre, en el proceso de estimación de SLAM.

Dependiente del proceso de estimación de SLAM.

Agente



Entorno



Sistema de control autónomo de A-SLAM basado en RL e integrado en ROS2 para un robot diferencial.

ÍNDICE




1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

2. Estado del arte

Aprendiendo a elegir metas

- Uso de RL (algoritmos A3C, DQN) para seleccionar fronteras objetivo.
- Navegación local clásica.

Niroui, F., et. al., 2019. Deep reinforcement learning robot for search and rescue applications: Exploration in unknown cluttered environments. DOI: 10.1109/LRA.2019.2891991



Aprendiendo a navegar


- Selección heurística de fronteras.
- Algoritmo TD3 de RL políticas de control con acciones continuas.

Cimurs, R., Suh, I. H., Lee, J. H., 2021. Goal-driven autonomous exploration through deep reinforcement learning. URL: <https://arxiv.org/abs/2103.07119>

A-SLAM (¡todo junto!)

- Navegación dependiente del proceso de estimación de SLAM.
- Recompensa compleja: completitud del mapa, reducción de incertidumbre.
- Representaciones multicanal del estado: maldición de la dimensionalidad y CNN.
- Aprendizaje por Refuerzo Profundo (Deep RL)

Zhao, S., et. al., 2024. Exploration- and exploitation-driven deep deterministic policy gradient for active slam in unknown indoor environments. DOI: 10.3390/electronics13050999



Alcalde, M., et. al., 2022. Daslam: Deep active slam based on deep reinforcement learning. DOI: 10.1109/LARS/SBR/WRE56824.2022.9996006


Li, Z., et. al., 2023. Autonomous exploration and mapping for mobile robots via cumulative curriculum reinforcement learning. URL: <https://arxiv.org/abs/2302.13025>

ÍNDICE



1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

3. Método propuesto



Aprendizaje por Refuerzo Q-learning: aprender el **retorno esperado** o valores q (suma de recompensas futuras acumuladas y descontadas).

Arquitectura neuronal Actor-Crítico:

- **Actor π_ϕ :** aprende la política de control. Estados del entorno $\rightarrow$ acciones óptimas.
- **Críticos $Q_{\theta_1}, Q_{\theta_2}$:** estima Q^* . Evalúa las acciones propuestas por el actor.

Modelo *Deep RL*: algoritmo *TD3*


Robusto frente a la sobreestimación de Q^* .

3. Método propuesto

Estado del entorno

$$S_t = [L_t, M_t^{LEM}, M_t^{GEM}, \sin(\psi_t), \cos(\psi_t), v_{t-1}, \omega_{t-1}]$$

- L_t : 500 puntos **LiDAR** 360°.
- M_t^{LEM} : mapa **ocupación** 24x24 px.
- M_t^{GEM} : mapa de **exploración** 24x24 px.
- $\sin \psi_t, \cos \psi_t$: **orientación** del robot sin discontinuidades.
- v_{t-1}, ω_{t-1} : **acciones** del paso anterior.



Espacio de acciones: continuo

$$a_t = [v_t, \omega_t]$$

- $v_t \in [-1, 1]$: velocidad lineal, interpolada al rango físico real $[0, 0'3]$ m/s.
- $\omega_t \in [-1, 1]$: velocidad angular, concuerda con el rango físico, en rad/s.



$$a = [v, w]$$

Dimensionalidad: **¡¡1656 elementos!!**


Dimensionalidad: **2 elementos**

3. Método propuesto

Estado del entorno: representación dual del mapa



(a) $s = 1$.



- M_t^{LEM} : mapa egocéntrico local (LEM)


Región del mapa original, centrada en el robot, reducida a dimensión 24x24 píxeles mediante *max pooling*.

Factor de escala $s > 1$ para capturar más o menos información del mapa original.

0: libre; 128: desconocido; 255: ocupado

3. Método propuesto

Estado del entorno: representación dual del mapa




- M_t^{GEM} : mapa global de exploración (*GEM*)


Rectángulo mínimo de la región ya explorada del mapa original, reducida a dimensión 24x24 mediante *nearest neighbor*.

La posición del robot se marca con el valor 128 de 3x3 píxeles.


0: inexplorado o desconocido; 255: conocido (libre + ocupado).



3. Método propuesto



Red TD3 con reducción de la dimensionalidad



3. Método propuesto

Función de recompensa multiobjetivo

$$R_t = \frac{r_{ctrl} + r_{obs} + r_{expl} + r_{time}}{k_s} + R_{term}$$

Penalizaciones

$$r_{ctrl} = r_{\omega} + r_v \quad r_{\omega} = -k_{\omega} \cdot \omega_t^2,$$

Vel. angulares elevadas $r_v = -k_v \cdot [10,0 \cdot (v_{target} - v_t)]^2$

Vel. lineales diferentes a objetivo

$$\text{Cercanía a obstáculos} \quad r_{obs} = \begin{cases} -20,0 & \text{si } d_{min} < 0,22 \\ 0,0 & \text{en otro caso} \end{cases}$$

$$\text{Tiempo empleado} \quad r_{time} = -k_t$$

$$\text{Colisión o timeout} \quad R_{term} = \begin{cases} -2,0 & \text{si colisión o vuelo} \\ -1,0 & \text{si tiempo agotado (timeout = 40 s)} \end{cases}$$

Incentivos

Aumento en el % de exploración $\Delta\rho^2 = (\rho_t - \rho_{t-1})^2$

$$r_{expl} = \begin{cases} \min(k_{e1} \cdot \Delta\rho^2, 1,0) \cdot k_{e2} & \text{si } \Delta\rho^2 > 0 \\ -k_{e3} & \text{en otro caso} \end{cases}$$


Éxito (exploración > 95%)

$$R_{term} = \begin{cases} +5,0 & \text{si éxito } (\rho \geq 95\%) \\ \dots & \end{cases}$$

3. Método propuesto

Arquitectura ROS2


Simulación



ROS2 Humble
Gazebo Classic

Nodos
Temas (topics)
Servicios
Procesos internos

Robot físico real



ÍNDICE

1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

4. Experimentación y resultados


Función de recompensa

Constante	Agente 1	Agente 2	Agente 3
k_s	1000,0	1000,0	1,0
k_w	2,0	3,0	0,3
k_v	2,0	3,0	0,3
k_{e1}	10,0	5,0	5,0
k_{e2}	100,0	100,0	0,5
k_{e3}	0,5	0,5	0,05
k_t	1,0	0,002	0,002

Resultado	Agente 1	Agente 2	Agente 3
Episodios con éxito	61,18 %	77,8 %	87,20 %
Episodios con colisión	37,79 %	21,0 %	12,80 %
Episodios con <i>timeout</i>	1,03 %	1,2 %	0,0 %

Agente 2



Trayectorias oscilantes...



**¡NO SE RESPETA LA
PENALIZACIÓN DE LA
VELOCIDAD ANGULAR!**

4. Experimentación y resultados

Resultados del entrenamiento del Agente 2



[0,075; 0,15]

Error de estimación o resolución
numérica con *MSBE* (*Mean
Squared Bellman Error*):



$$\sqrt{0,15} \approx 0,387$$

$$\dot{\epsilon} r_{\omega} \ll MSBE?$$

r_{ω} dividido por $k_s = 1000$, por lo
que es del orden de
 10^{-3} ; (0,001).


$$10^{-3} \ll 0,387$$

**ENMASCARADA POR EL
RUIDO DE APROXIMACIÓN**




4. Experimentación y resultados

Resultados del Agente 3



Reajuste de los pesos:


incentivos en el orden de magnitud de 10^{-1} , garantizando que la señal sea comparable a la precisión de la red.




4. Experimentación y resultados

Despliegue del Agente 3 en diferentes entornos

Aunque mantiene la tendencia a dirigirse hacia regiones inexploradas, las diferencias en la representación del entorno entre escenarios limitan su capacidad de generalización y su rendimiento.




(a) 6×6 m.




(b) 10×10 m.

4. Experimentación y resultados

Despliegue en el robot real




Malformación de mapas: plano de exploración del LiDAR y el plano del suelo no son perfectamente paralelos, para distancias elevadas las medidas del sensor pueden sobrepasar las paredes artificiales del escenario y registrar puntos situados fuera de los límites previstos.







4. Experimentación y resultados

Despliegue en el robot real



Movimientos seguros: no colisiona :)



ÍNDICE

1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros


5. Conclusiones y trab. futuros




- Eficacia del método propuesto afrontar el problema del A-SLAM:
 - Reducción de la dimensionalidad con CNN 1D y 2D.
 - Éxito al desplegar el agente sobre el escenario entrenado.
 - El robot físico real no colisiona.
- Publicación en Jornadas de Automática 2026: <https://doi.org/10.17979/ja-cea.2026.47.13735>
- Diferencias espaciales entre los entornos limitan la capacidad de generalización...



... ¡mejorar la **generalización** aplicando **curriculum** al entrenamiento: aumentar progresivamente la dificultad y variando entre escenarios!



Li, Z., et. al., 2023. Autonomous exploration and mapping for mobile robots via cumulative curriculum reinforcement learning. URL: <https://arxiv.org/abs/2302.13025>




Control autónomo de un robot móvil usando ROS2, Aprendizaje por Refuerzo y SLAM

Máster Universitario en Ingeniería de Sistemas y de Control

Estudiante: Javier Arambarri Calvo

Directores: Raúl Fernández Fernández,
Jesús Chacón Sombria

Curso académico: 2025/2026



Trabajo de Fin de Máster - 21/09/2026